

TP 3 – Clustering de documents textuels

Hany El Atlassi

15 septembre 2026

1 Démarche et résultats

J'ai appliqué un clustering non supervisé (K-Means) sur le corpus BBC News. Les 5 catégories d'origine : **sport** (511 articles), **business** (510), **politics** (417), **tech** (401) et **entertainment** (386), pour un total de 2225 articles.

J'ai d'abord transformé chaque article en vecteur TF-IDF (mots vides anglais retirés, termes trop rares ou trop fréquents filtrés), ce qui m'a donné une matrice de 2225 documents pour 9136 termes. J'ai fixé le nombre de clusters à $k = 5$, un choix que j'ai confirmé avec la courbe du coude et le score de silhouette, et qui correspond au nombre de catégories réelles afin de pouvoir comparer directement les deux. J'ai ensuite entraîné K-Means (**k-means++**, 10 initialisations) sur cette matrice.

En regardant les 10 termes les plus proches de chaque centroïde, j'ai pu identifier le thème dominant de chaque cluster :

Cluster	Termes principaux	Thème
0	people, mobile, technology, users, music, digital, games, phone, software, net	tech
1	game, england, win, cup, match, team, players, injury, play, club	sport
2	film, best, awards, award, band, festival, music, actor, star, album	entertainment
3	mr, labour, election, blair, party, brown, government, howard, minister, tory	politics
4	mr, growth, government, company, economy, market, bank, sales, oil, firm	business

J'ai ensuite croisé ces clusters avec les catégories réelles, ce qui donne le tableau de contingence suivant :

Catégorie \ Cluster	0	1	2	3	4
business	7	0	0	3	500
entertainment	5	2	321	0	58
politics	4	1	0	274	138
sport	0	479	2	0	30
tech	363	8	5	0	25

J'ai constaté que chaque cluster a bien un unique thème dominant, et j'ai calculé deux indices de comparaison : un Adjusted Rand Index (ARI) de 0.695 et une Normalized Mutual Information (NMI) de 0.743.

2 Analyse et interprétation

Le clustering n'a accès qu'à la proximité des vecteurs TF-IDF : un document est placé dans le cluster dont le centroïde partage le plus de termes fréquents et discriminants avec lui. J'ai

remarqué que les catégories dont le vocabulaire est très spécifique se retrouvent naturellement bien isolées : le sport a son propre lexique (*match, team, club, win*) qui n'apparaît presque jamais ailleurs, ce qui explique pourquoi j'ai retrouvé 479 des 511 articles **sport** (94%) dans le même cluster. À l'inverse, j'ai observé que **business** et **politics** partagent un vocabulaire institutionnel et économique commun (*mr, government, growth, market*), car la presse traite souvent les mêmes événements (budget, décisions gouvernementales, croissance) sous ces deux angles à la fois. C'est ce chevauchement lexical, et non un défaut de l'algorithme, qui explique pourquoi 138 articles **politics** se retrouvent absorbés par le cluster **business**, et pourquoi 58 articles **entertainment** (souvent liés à l'industrie du divertissement en tant qu'activité économique) le sont également.

J'ai aussi voulu vérifier si le déséquilibre des classes de départ (511 articles pour **sport** contre 386 pour **entertainment**, un rapport d'environ 1.3) expliquait les erreurs observées, mais ce n'est pas ce que j'ai constaté : la catégorie la plus mal reconstituée (**business**, avec 500 documents correctement isolés sur 510 mais 268 documents d'autres classes qui lui sont rattachés) n'est ni la plus grande ni la plus petite. J'en conclus que c'est surtout la proximité sémantique entre thèmes voisins qui pèse sur le résultat ; un déséquilibre plus marqué aurait en revanche pu favoriser les grandes classes, K-Means cherchant à minimiser une inertie globale que les clusters les plus peuplés dominant davantage.

J'ai choisi l'ARI et la NMI parce que ce sont deux indices externes conçus pour comparer un clustering à un étiquetage de référence sans supposer que les identifiants de cluster correspondent aux identifiants de classe (rien n'oblige le cluster 4 à s'appeler **business**). L'ARI corrige en plus l'accord attendu par simple hasard, ce qui m'a semblé plus fiable qu'un taux de concordance brut, surtout que mes classes n'ont pas toutes la même taille. La valeur de 0.695 que j'ai obtenue me montre que l'accord entre mon clustering et les catégories réelles est nettement supérieur à ce qu'un partitionnement aléatoire produirait, tout en restant loin de l'accord parfait, ce qui correspond bien aux confusions que j'ai observées entre **business** et **politics**. La NMI mesure quant à elle la quantité d'information partagée entre les deux partitions, normalisée entre 0 et 1 : la valeur de 0.743 que j'ai obtenue m'indique que connaître le cluster d'un document réduit fortement mon incertitude sur sa catégorie réelle, ce qui confirme que le vocabulaire TF-IDF capture bien la structure thématique du corpus, malgré les zones de recouvrement lexical entre certains sujets proches.